

STUDI OPTIMALISASI PENGGUNAAN BAHAN BAKAR DAN REDUKTOR
PADA PROSES KALSINASI UNIT BISNIS PERTAMBANGAN NIKEL KOLAKA
DENGAN PENERAPAN MACHINE LEARNING SYSTEM

Executive Summary



Phase

01


Pendahuluan



Tantangan Industri Pertambangan dan Pengolahan Mineral

Peluang:

Implementasi AI dalam optimasi proses produksi



Tujuan



Identifikasi teknologi
smart factory sesuai
kondisi operasi FeNi UBP
Kolaka PT ANTAM

-

Membangun model
machine learning untuk
optimasi konsumsi
reduktor dan bahan bakar

Melakukan reviu
dan analisis data-
data teknis dan alur
proses kerja

Mengolah data
proses pengolahan
logam pada kondisi
existing untuk
mendapatkan
model kondisi
existing proses
kalsinasi

Membangun model
machine learning
untuk pengaturan
pengoperasian
RKEF

Membuat gap
analysis model
machine learning
terhadap kondisi
existing pengaturan
pengoperasian
RKEF

Ruang Lingkup



ANTAM's production activities at the Southeast Sulawesi Nickel Mining Business Unit (11/11/2019). ANTAM marked the highest ferronickel production performance in 2020.

Phase

03


Alur

Operasional



Existing



Diagram Alir Proses Produksi Feronikel



Proses RKEF



Rotary Dryer

- pengering berputar (rotary drier) berfungsi menghilangkan kandungan air bebas (terikat secara fisik) dari konsentrat



Rotary Kiln

- tungku kalsin/reduksi berputar (Rotary Kiln Calcine/Reduction), mengikat sebagian oksidasi (reaksi reduksi sebagian) dari bijih oksida besi dan nikel; produknya disebut **kalsin**

Electric Furnace




- tungku Listrik (Electric Furnace) berfungsi melebur kalsin dan memisahkan logam feronikel (FeNi) dari pengotor (terak/slag)

Proses RD & RK



- Dua rotary dipakai yakni rotary dryer dan rotary kiln
- Rotary dryer bertujuan untuk menghilangkan **moisture content**
- Rotary kiln atau proses kalsinasi akan menghilangkan sisa air serta **mereduksi** sebagian bijih dengan feed batubara
- Bijih yang telah melewati proses ini akan berubah menjadi **kalsin** dengan suhu sekitar 900 °C

Proses EF (Smelting)




- Ferronikel cair mentah yang dihasilkan pada suhu 1450°C, dengan kandungan nikel 20–40% dan besi 80–60%.
- Slag cair, yang terdiri dari senyawa SiO_2 , MgO , dan FeO , dengan kandungan nikel yang sangat rendah (0,1–0,2%), dihasilkan pada suhu 1550°C.
- Gas buang panas, terutama berupa karbon monoksida CO , dilepaskan pada suhu 900°C.
- logam cair dituangkan ke dalam air yang bergerak untuk menghasilkan partikel berbentuk bulat kecil yang dikenal sebagai Fe-Ni shot

The background features a white canvas with several green geometric shapes: a large rounded rectangle on the left, a smaller rounded rectangle overlapping its bottom right, and a large circle on the right. Two thick black horizontal bars are present: one in the upper right corner and another in the lower left, partially overlapping the green shapes.

Pengaturan Existing

Pengaturan Existing



Berdasarkan panduan,
Konsumsi bahan bakar =
115 kg/tco; konsumsi
reduktor = 67 kg/tco.

Pada praktiknya, bisa
tidak sesuai karena faktor
GCV dan FC coal, MC
ore, suhu kalsin dan
pengaturan EF.

Karena itu butuh
disetting lagi

Bahan bakar disetting jika
T Kalsin tidak sesuai, dgn
mengatur ton coal, katup
PRY, SEC, dan AF Ratio.

Reduktor disetting ketika
komposisi produk metal
tidak sesuai.

Perubahan pengaturan
dapat dilihat dampaknya
pada produk 16 jam
kemudian.

Pada EF, load beban
(daya) dikunci nilainya.
Pengaturan dilakukan
pada nilai impedance.

Pengaturan EF
disesuaikan jika: kiln
turun chargenya, atau
kalsin kurang bagus,
karena Lol tinggi akibat
kurang lama dipanaskan,
disebabkan kualitas
batubaranya.


Phase

04

Machine Learning Modeling



Ilustrasi proses produksi yang dimodelkan




Machine Learning based Optimization


- Machine learning hanya bisa memodelkan sistem, lalu **memprediksi output** dengan memasukkan input yang mau diproses
- Reduktor dan bahan bakar **merupakan input** dari sistem RKEF
- Karena itu, perlu tambahan proses optimisasi matematis yang dapat merekomendasikan input yang optimal dengan diberikan model system dan target output


Model machine learning = $f(x)$

Predict $\hat{Y} = f(x) \rightarrow$ save model $f(x)$



Alur Kerja Pemodelan



The background features a white canvas with several decorative elements. On the left, there is a large, light green rounded rectangle. Overlapping its right side is a smaller, lighter green circle. A thick black horizontal bar is positioned at the top right of the image. Another thick black horizontal bar is located below the word 'Learning' on the left side.

Model Machine Learning

Catatan Sumber Data Eksperimen 1



Hanya dari RK3 dan EF3

ML butuh pemasangan data input-output yang akurat, line lain tidak bisa ditrace outputnya



Hanya dari data Januari 2021 Data 2023, 2024 banyak variable yang kosong sehingga rentan bias jika dipaksakan diikutkan dalam pemodelan

Inputasi hanya bisa dilakukan jika data kosong dibawah 30%



Variabel rasio masih dilibatkan dalam training


E.g. Fe/Ni, S/M, A/F Ratio, Reductor Ratio
Variable2 input yang berkolerasi linear dibuang salah satu.



Catatan Sumber Data Eksperimen 2 (Revisi)



Hanya dari RK3 dan EF3



Hanya dari data tengah Juli
2024 hingga tengah Nov
2024

Inputasi dilakukan
dengan interpolasi
sehingga data penuh Juli-
Des 2024




Variabel rasio tidak
dilibatkan dalam training

Contoh: Fe/Ni, S/M, A/F
Ratio, Reductor Ratio




Visualisasi Data: Variabel Input RK

Histograms of RK Input Columns




Visualisasi Data: Variabel Output RK

Histograms of RK Output Columns




Visualisasi Data: Variabel Input EF

Histograms of EF Input Columns



Visualisasi Data: Variabel Output EF

Histograms of EF Output Columns




Feature Selection dan Data Normalization

Pemilihan fitur dari seluruh variabel/kolom dari 3 file sumber data.

Variabel dipilih berdasarkan korelasi yang terkait proses produksi berdasarkan informasi *domain expert (process engineer)*, sehingga dihasilkan 32 fitur

Masing-masing kolom memiliki skala nilai yang berbeda-beda. Karena itu, diperlukan tahapan pre-processing untuk menyeragamkan data.



Algoritma Machine Learning yang Diuji

1. Random Forest (RF)
2. Multilayer Perceptron (MLP)
3. Support Vector Regressor (SVR)
4. Ridge Regression (RR)
5. Lasso
6. K-Nearest Neighbor (KNN)
7. Gaussian Process Regression (GPR)
8. Convolutional Neural Network (CNN)
9. XGBoost
10. CatBoost

Parameter Evaluasi

Mean Absoluter Error (MAE)

- rata-rata kesalahan absolut antara nilai aktual (y_i) dan nilai prediksi ($\hat{y}_i$). Semakin kecil nilai MAE, semakin baik model dalam memprediksi nilai mendekati data aktual.

- $$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Mean Squared Error (MSE)

- rata-rata dari kuadrat kesalahan antara nilai aktual dan prediksi. Dengan mengkuadratkan kesalahan, lebih sensitif terhadap outlier dibanding MAE.

- $$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Root Mean Squared Error (RMSE)

- akar kuadrat dari MSE, sehingga mengembalikan skala kesalahan ke unit yang sama dengan nilai aslinya. RMSE juga sensitif terhadap outlier, seperti MSE.

- $$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

ML Model Error (MAE)

Tabel 5.17 Hasil Evaluasi MAE dari 10 Model

Column	RF	MLP	SVR	RR	LASSO	KNN	GPR	CNN	XGBOOST	CATBOOST
metal_temp	1,81	1,64	3,92	0,49	6,42	0,52	0,73	2,76	1,41	2,20
ni_met	0,06	0,17	0,23	0,02	0,35	0,03	0,04	0,22	0,05	0,09
c_met	0,01	0,02	0,03	0,01	0,04	0,00	0,00	0,02	0,01	0,01
si_met	0,01	0,03	0,04	0,02	0,05	0,01	0,01	0,04	0,01	0,01
fe_met	0,05	0,10	0,16	0,02	0,30	0,02	0,03	0,20	0,05	0,08
s_met	0,01	0,01	0,01	0,00	0,02	0,00	0,00	0,01	0,01	0,01
ni_slag	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
fe_slag	0,12	0,21	0,33	0,13	0,46	0,06	0,05	0,26	0,07	0,15
t_kalsin	13,88	14,55	9,84	1,25	19,70	16,67	2,71	14,81	8,16	7,45
pic_161	0,41	0,25	0,26	0,05	0,55	0,44	0,06	0,47	0,18	0,17

Best model

ML Model Error (MSE)

Tabel 5.18 Hasil Evaluasi MSE dari 10 Model

Column	RF	MLP	SVR	RR	LASSO	KNN	GPR	CNN	XGBOOST	CATBOOST
metal_temp	18,09	4,66	18,92	0,41	83,22	5,36	4,02	11,29	11,51	15,86
ni_met	0,01	0,29	0,49	0,00	1,24	0,17	0,01	0,51	0,01	0,18
c_met	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
si_met	0,00	0,00	0,00	0,00	0,01	0,00	0,00	0,00	0,00	0,00
fe_met	0,01	0,14	0,24	0,00	0,94	0,01	0,01	0,50	0,01	0,11
s_met	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
ni_slag	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
fe_slag	0,30	0,50	0,95	0,21	2,47	0,95	0,16	0,75	0,12	0,65
t_kalsin	415,97	358,96	153,15	2,67	756,94	573,72	28,43	394,21	122,90	122,20
pic_161	0,29	0,10	0,11	0,00	0,46	0,35	0,01	0,37	0,06	0,05

Best model

ML Model Error (RMSE)

Tabel 5.19 Hasil Evaluasi RMSE dari 10 Model

Column	RF	MLP	SVR	RR	LASSO	KNN	GPR	CNN	XGBOOST	CATBOOST
metal_temp	4,25	2,16	4,35	0,64	9,12	2,32	2,01	3,36	3,39	3,98
ni_met	0,09	0,20	0,27	0,03	0,42	0,16	0,09	0,27	0,09	0,16
c_met	0,02	0,03	0,03	0,01	0,05	0,02	0,01	0,03	0,01	0,02
si_met	0,02	0,04	0,05	0,02	0,07	0,04	0,02	0,04	0,02	0,03
fe_met	0,08	0,14	0,19	0,02	0,37	0,10	0,09	0,27	0,09	0,13
s_met	0,01	0,01	0,01	0,00	0,03	0,01	0,01	0,01	0,01	0,01
ni_slag	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
fe_slag	0,21	0,27	0,37	0,17	0,60	0,37	0,15	0,33	0,13	0,31
t_kalsin	20,40	18,95	12,38	1,63	27,51	23,95	5,33	19,85	11,09	11,05
pic_161	0,54	0,32	0,33	0,06	0,68	0,59	0,12	0,61	0,25	0,22

Best model

Optimasi Reduktor

- *Tabel 5.1 Error antara output optimisasi dengan output lapangan dan jumlah constraint violation*

Output Variabel	MSE	MAE	RMSE	Constraint	Constraint Violation
metal_temp	607,6819	20,00725	24,6512	$X > 1300$	0
ni_met	1,070592	0,924925	1,034694	$X > 17\%$	0
c_met	0,004787	0,058537	0,069186	$1\% \leq X \leq 3\%$	0
si_met	0,018284	0,106168	0,135217	$1\% \leq X \leq 2\%$	0
fe_met	1,382395	1,057902	1,175753	$X > 0$	0
s_met	0,016438	0,117229	0,128213	$0\% < X \leq 0.4$	0
ni_slag	4,24E-05	0,00539	0,006509	$X > 0$	0
fe_slag	0,661482	0,653821	0,813315	$X > 0$	0
t_kalsin	7299,165	81,30756	85,43515	$X > 600$	0
pic_161	5,902984	2,351679	2,429606	$X \approx 0$	0
loi_kalsin	0,155547	0,308954	0,394395	$0\% < X \leq 1\%$	0

Tabel 6.1 Ringkasan Perhitungan Konsumsi Reduktor

Parameter Evaluasi	Nilai
Total Efisiensi (Ton)	129.73
Total Jam	117
Total Hari	4.875
Rata-Rata Efisiensi Per Jam (Ton)	1.10
Rata-Rata Efisiensi Per Hari (Ton)	26.61
% Efisiensi	20.28



Phase

0

4



Prototype Deployment



User Interface

Optimasi Proses Rotary Kiln dan Electric Furnace

Aplikasi ini digunakan untuk **menghitung konfigurasi input yang diperlukan** dalam proses **rotary kiln** dan **electric furnace** berdasarkan **komposisi bahan mentah** yang dimasukkan oleh pengguna.

Untuk menggunakan aplikasi ini, silakan masukkan komposisi bahan mentah yang diinginkan pada kolom input di bawah ini(value placeholder dapat diubah).

Masukkan Ni:

2,0550

- +

Masukkan Fe:

13,2650

- +

Masukkan SiO2:

39,8400

- +

Masukkan CaO:

0,4600

- +

Masukkan MgO:

144,2100

- +

Masukkan Charge Klin:

2242,2400

- +

Kirim

Input

Parameter	Value
Tegangan (V)	795.0539900303696
Arus (A)	29.699681283770772
Load (MW)	2.7536719063685244
rpm	0.5272558183601984
pry_p	1200.5172792744836
sec_p	203.77309243598603
pry_v	169.5311836490215
sec_v	577.4820157810833
total_coal	4792.879067904727


1. Transformasi *smart factory*, dapat dimulai dengan implementasi model *machine learning* dan optimisasi untuk efisiensi penggunaan bahan bakar dan reduktor.
2. Implementasi model machine learning membutuhkan ketersediaan dan manajemen data operasional yang terstandarisasi dan lengkap.
3. Model machine learning yang dibangun berhasil memprediksi nilai 11 output sistem RKEF dengan nilai absolute error rata-rata yang sangat rendah yaitu sebesar 1.25° Celcius untuk temperatur kalsin
4. Optimisasi berhasil menurunkan konsumsi reduktor dengan tetap mempertahankan kualitas output sesuai pada target idealnya. Rata-rata efisiensi harian yang dapat dicapai hingga 20.28%.

Kesimpulan



The background features a white canvas with several green geometric shapes: a large rounded rectangle on the left, a large circle in the lower center, and a smaller circle on the right. Two thick black horizontal bars are present: one in the upper right and another in the lower left, partially overlapping the green shapes.

**Thank
You**

The background features a white canvas with several decorative elements. On the left, there is a large, light green rounded rectangle. Overlapping its right side is a smaller, semi-transparent light green circle. A thick black horizontal bar is positioned at the top right of the image. Another thick black horizontal bar is located below the text, starting from the left edge of the green rounded rectangle and extending to its right edge.

Lampiran Revisi

Perkembangan Eksperimen 2 (Revisi)

ML Model Error (MAE)

Tabel Hasil Evaluasi MAE dari 10 Model

Feature	CatBoost	GPR	GRU	Lasso	MLP	RandomForest	Ridge	SVR	XGBoost	kNN
c_met	0.061368718	0.120939101	0.165985374	0.16842689	0.129751854	0.071744563	0.149576439	0.139732959	0.05756753	0.103293461
fe_met	0.295272794	0.786229847	1.031400929	1.097723893	0.718769152	0.344665751	0.776437756	0.753348874	0.270222527	0.547515831
fe_slag	0.353663615	0.724157207	0.887486523	0.944139133	0.77094406	0.411879721	0.810836094	0.803288346	0.373275235	0.602100946
loi_kalsin	0.08865659	0.093669326	0.146517637	0.147712664	0.146435853	0.091035741	0.145454777	0.091547302	0.081632861	0.111990509
metal_temp	6.118249391	8.789918961	11.00518082	11.06704252	10.24744039	6.151054513	10.69791307	9.835073675	6.256927102	8.50627061
ni_met	0.322643447	0.782623529	1.013791676	1.080837122	0.785221699	0.367977405	0.814969354	0.774444344	0.301056482	0.553242033
ni_slag	0.003001009	0.004165749	0.004930736	0.00535858	0.004821132	0.003129222	0.004908245	0.004530312	0.00306815	0.003847654
pic_161	0.828251192	0.947194856	1.008465852	1.052941679	1.038285077	0.827880704	1.035925937	0.958493394	0.948000078	1.026177101
s_met	0.054605995	0.152206181	0.234839942	0.253433867	0.119363314	0.05608087	0.157642404	0.16035743	0.049801219	0.100009066
si_met	0.0865326	0.168422579	0.206921332	0.218240073	0.192582357	0.097375526	0.203755912	0.183608211	0.087811383	0.146132039
t_kalsin	29.88515353	42.78817062	44.18974273	47.26615869	45.80004935	30.11949402	49.12366326	41.28462686	30.73216358	41.60471479

Best model: Lebih baik dari paper referensi 2024 (SNNC, Korea) dengan MAE t_lalsin yaitu 38.22 Celsius (dari 6 bulan data per menit)

Perkembangan Eksperimen 2 (Revisi)

ML Model Error (MSE)

Tabel Hasil Evaluasi MSE dari 10 Model

Feature	CatBoost	GPR	GRU	Lasso	MLP	RandomForest	Ridge	SVR	XGBoost	kNN
c_met	0.007535346	0.027030264	0.045251513	0.04635535	0.026718667	0.009933538	0.034024233	0.033531632	0.007106261	0.020568873
fe_met	0.188440952	1.069618751	1.549351528	1.736612581	0.886113842	0.278033439	0.959889115	0.966398132	0.158608656	0.661309478
fe_slag	0.23091716	0.891140575	1.227026868	1.3650033	1.011791535	0.320183219	1.043309359	1.070614331	0.263174781	0.699427492
loi_kalsin	0.02171745	0.040236291	0.046051532	0.045916385	0.044127401	0.023901846	0.044541217	0.052982723	0.021726904	0.035914526
metal_temp	75.91386975	151.7270366	200.6819323	207.9543771	174.3912361	78.5473188	200.2328148	193.3193091	82.79473294	141.5249714
ni_met	0.228717778	1.11163161	1.589887122	1.799548278	1.062207415	0.31394813	1.101846516	1.128875466	0.21633192	0.71840674
ni_slag	1.52044E-05	3.64011E-05	4.54626E-05	5.01809E-05	3.75466E-05	1.67391E-05	3.87336E-05	4.28734E-05	1.69369E-05	2.88734E-05
pic_161	1.803824832	3.218658505	3.685518111	3.905994767	3.28907357	1.747519032	3.662478336	3.597459695	2.261110136	2.826565459
s_met	0.008342228	0.076915684	0.107403596	0.121741066	0.027600603	0.009231885	0.048253934	0.070984086	0.007957882	0.030996854
si_met	0.01681745	0.057206119	0.083277406	0.087401092	0.072554139	0.023950591	0.080674203	0.081386243	0.017571868	0.051476633
t_kalsin	2095.240858	7753.440166	5539.322531	6223.922344	4968.089635	2251.792694	6082.632766	5221.181342	2190.828168	4445.318365

Best model

Perkembangan Eksperimen 2 (Revisi)

ML Model Error (RMSE)

Tabel Hasil Evaluasi RMSE dari 10 Model

Feature	CatBoost	GPR	GRU	Lasso	MLP	RandomForest	Ridge	SVR	XGBoost	kNN
c_met	0.086806371	0.16440883	0.212724031	0.215302927	0.163458455	0.099667137	0.184456588	0.183116444	0.084298643	0.143418525
fe_met	0.43409786	1.034223743	1.2447295	1.317805972	0.9413362	0.527288763	0.97973931	0.983055508	0.398257023	0.813209369
fe_slag	0.480538406	0.944002423	1.107712448	1.168333557	1.005878489	0.565847346	1.021425161	1.034704949	0.513005635	0.836317818
loi_kalsin	0.147368416	0.200589857	0.214596208	0.214281089	0.21006523	0.154602219	0.211047902	0.230179763	0.147400489	0.189511282
metal_temp	8.712856578	12.3177529	14.16622505	14.42062333	13.2057274	8.862692526	14.15036448	13.90393143	9.099161112	11.89642683
ni_met	0.478244476	1.054339419	1.260907261	1.341472429	1.030634472	0.560310744	1.049688771	1.062485513	0.465114954	0.84758878
ni_slag	0.003899286	0.006033329	0.006742598	0.007083851	0.00612753	0.004091342	0.006223632	0.006547776	0.004115446	0.005373399
pic_161	1.343065461	1.794062013	1.919770328	1.976358967	1.813580318	1.321937605	1.913760261	1.896697049	1.503698818	1.681239263
s_met	0.0913358	0.27733677	0.327724879	0.348914124	0.166134291	0.096082698	0.219667781	0.266428388	0.089206959	0.176059235
si_met	0.129682112	0.239178007	0.288578249	0.295636756	0.269358755	0.154759785	0.284032046	0.285282742	0.132558923	0.226884624
t_kalsin	45.773801	88.05362097	74.42662515	78.89183952	70.4846766	47.45305779	77.99123519	72.25774244	46.80628342	66.67322075

Best model